

UD04. Big data

Sitio: [Plataforma de Teleformación Galega](#)
Curso: G2501206 Dixitalización aplicada ao sistema produtivo
Libro: UD04. Big data

Impreso por: Martín Gil Blanco
Data: mércores, 20 de maio de 2026, 10:11 AM

Táboa de contidos

1. Os datos e a ciencia de datos

2. O ciclo de vida do dato

3. Adquisición

4. Limpeza e preparación dos datos

5. O almacenamento de datos

5.1. Vantaxes e desvantaxes do almacenamento na nube

5.2. A seguridade dos datos

6. Análise de datos

6.1. Análise de clústeres

7. Ciencia de datos

7.1. Machine learning

7.2. Deep learning

8. Usos do big data

9. Recursos

1. Os datos e a ciencia de datos

Cando empregamos dispositivos dixitais estamos a xerar datos constantemente. Todos os eventos que xeramos (acceder a unha páxina web, o clic do rato na computadora, o movemento dos dedos nun smartphone, os ficheiros que descargamos, os pasos que damos ou o latido do noso corazón) son datos que poden ser rexistrados e almacenados.

Estes datos illados non achegan información de interese, pero ao combinalos cos outros datos podemos obter información moi relevante: que produtos se adoitan vender conxuntamente, que secuencias seguen os usuarios para chegaren a un recurso concreto, que colocación é máis axeitada para un anuncio nunha web para que os usuarios cliquen nel, que pautas de sono poden estar vinculadas a unha enfermidade ...

Os **datos** son todos estes rexistros de variables, eventos ou transaccións “sen procesar”, e unha vez que procesamos estes datos para obtermos un valor deles, o que obtemos é **información**.



Unha das principais vantaxes dos sistemas dixitais con respecto aos analóxicos é precisamente a información que proporcionan: non só permiten rexistrar calquera evento que poida ser de interese da súa utilización, senón que estes datos poden ser facilmente almacenados e procesados para obter información a partir deles.


Todos estes datos que se están a xerar constantemente a partir dos sistemas dixitais son o que da forma ao **big data**. O **big data** é un conxunto de tecnoloxías que teñen por obxectivo capturar e almacenar grandes volumes de datos e analízalos para obter información a partir deles para facilitar a toma de decisións.

Para iso traballará con gran cantidade de datos, entre os que podemos atopar información estruturada (rexistros de información con campos “constantes”, como o rexistro dunha venda, que sempre inclúe a mesma información: o cliente, os produtos, o prezo, o IVA, os descontos, ...) pero tamén información non estruturada (rexistros de información “variable”, como o rexistro dos clics que un usuario realiza nunha páxina web: se o clic se produce nun vídeo interesará gardar a posición do vídeo na web, a súa resolución ou o tamaño do frame no que se reproduce o vídeo; se o clic se produce nunha ligazón de texto pode ser de interese gardar o contido dese texto, a cor coa que se amosaba ou a súa posición na páxina; se o clic se produce nun anuncio interesará gardar quen era o anunciante, que tamaño tiña o banner no que se amosaba o anuncio, a súa posición, ...).



2. O ciclo de vida do dato

O ciclo de vida do dato son as distintas fases polas que pasa un dato desde que se obtén a partir dun sistema ou dunha fonte de información ata que se elimina dos soportes de almacenamento:



- **Adquisición de datos:** o primeiro paso será recompilar os datos necesarios, que poden proceder de diversas fontes: ficheiros, bases de datos, APIs, sensores en tempo real, procuras en internet (**web scraping**), etc.
- **Limpeza e preparación:** xeralmente os datos recompilados son datos heteroxéneos, procedentes de fontes moi diversas, e en ocasións están incompletos ou son "ruidosos" ou inexactos, polo que para poder cruzalos e realizar consultas combinando as distintas fontes de información adoita ser preciso limpálos e preparalos. Se por exemplo queremos consultar os prezos de determinados produtos en varias tendas en liña para facermos unha comparación e un seguimento deles, o que atoparemos será que en cada tenda se empregarán distintos códigos para identificar os mesmos produtos, terán distintos prezos, e incluso poden ter distintas descrições. Para podermos comparalos e cruzar os datos necesitamos homoxeneizar estes datos para asegurar que os produtos referidos sexan os mesmos en todas as webs das que traemos os datos.
- **Almacenamento dos datos:** non só é importante dispor do espazo suficiente de almacenamento para rexistrar todos os datos adquiridos, senón que tamén será preciso poder procesalos, analízalos e distribuílos de forma rápida e segura.
- **Análise de datos:** unha vez recollidos os datos é necesario procesalos para convertelos en información. A análise de datos permite identificar nos datos padróns, tendencias ou relacións que poidan proporcionar información. A partir de datos históricos do pasado se extrae información para guiar as decisións no presente, xeralmente por medio de técnicas de visualización de datos ou análises estatísticas.
- **Ciencia de datos:** por medio de técnicas de aprendizaxe automática, estatísticas e outras técnicas analíticas se definen algoritmos baseados en datos para prognosticar resultados futuros. Estes modelos se adestran empregando datos históricos e logo se avalían empregando conxuntos de datos de proba para determinar a súa precisión e o seu rendemento. Tras a comprobación dos resultados se poden axustar parámetros do modelo para axustar a predición e mellorar a súa precisión.
- **Distribución:** compártese a información cos usuarios para os que poida ser de utilidade. Débese proporcionar a cada usuario a información que precisa e cando a precise, garantindo en todo momento a seguridade dos nosos datos.
- **Eliminación:** en xeral os datos descártanse e se eliminan cando xa non son de utilidade.

Aínda que en xeral os datos pasan por estas fases de forma lineal, isto non sempre é así, xa que en ocasións é preciso limpar os datos para mellorar a precisión dun modelo, por exemplo, ou é preciso recoller máis datos para dar un resultado fiable, e isto implica realizar diversas iteracións entre as distintas fases do ciclo de vida.

3. Adquisición

Os sistemas de [big data](#) empregan datos procedentes de fontes moi diversas:

- **Datos dos sistemas operacionais:** as empresas e organizacións polo xeral empregan aplicacións para levar a cabo as operacións do seu día a día (de ahí o seu nome de "operacionais"), que adoitan almacenar toda a súa información en bases de datos. Entre estas aplicacións destacan:
 - **ERP** (enterprise resource planning), aplicacións que permiten xestionar de forma integrada as operacións máis habituais da empresa: compras, vendas, xestión do almacén, nóminas, etc).
 - **CRM** (customer relationship management): ferramentas de xestión das relacións coa clientela, que facilitan a interacción cos clientes automatizando tarefas repetitivas (envío de correos, ofertas, rexistros de compras, etc.), optimizar os procesos de venda, realizar operacións de fidelización de clientes, xestionar solicitudes e queixas ou realizar estudos da clientela (pronósticos de venda, segmentación de clientes,...).
 - **POS:** sistemas de punto de venda.
 - Aplicacións de xestión financeira: dos que se pode obter información das transaccións bancarias, saldos de caixa, pagamentos en liña, facturación, etc.
- **Datos xerados polos usuarios**
 - Nas redes sociais: publicacións, likes, relacións entre usuarios, fotos, vídeos, etc.
 - En foros e blogs: comentarios, recensións, comunidades en liña, etc.
 - Recollidos dos sitios webs corporativos por medio de consultas ou formularios específicos.
- **Dispositivos e sensores**
 - Sistemas **IoT** (Internet of Things): sensores industriais, dispositivos intelixentes (termómetros, cámaras, dispositivos wearables, ...).
 - Telemetría xerada por vehículos, maquinaria pesada, avións, ...
- **Información recollida polas aplicacións**
 - Aplicacións móbiles (actividade dos usuarios nas apps).
 - Localización e información do tráfico, radares, etc. recollida polos sistemas de navegación GPS.
 - Sistemas de venda en liña, tanto relativa ás operacións realizadas polos usuarios na web (información de clics realizados na web, rexistros de navegación, tempo de estadía na web, rexistros de compras,...) como das características deses usuarios recadadas polas aplicacións de venda (sistema operativo, navegador, localizacións, etc.).
- **Datos públicos e abertos**
 - Publicados por administracións públicas, empresas ou organizacións sen ánimo de lucro ou de formación: a aposta de diversas administracións pola transparencia favoreceu a aparición de repositorios de información públicos abertos nos que se comparten estatísticas oficiais, censos, resultados das votacións, etc.
 - Bases de datos científicas: publicacións académicas, resultados de experimentos, información xenómica, etc.
- **Datos multimedia**
 - Imaxes e vídeos: procedentes das redes sociais pero tamén de cámaras de seguridade, sistemas de recoñecemento facial, sistemas de imaxe por satélite (Google Maps), etc.
 - Audio: gravacións de voz, música ou chamadas telefónicas.
- **Datos de terceiros:** as novas tecnoloxías deron lugar á aparición de novas oportunidades de negocio, ao aparecer empresas que recollen e venden conxuntos de datos (como Nielsen, Experian ou LexisNexis), ou que proporcionan APIs (interfaces de programación) para acceder a información procedente de servizos externos.
- **Datos xerados por máquinas**
 - Modelos predictivos: datos creados por sistemas de intelixencia artificial e aprendizaxe automática.
 - Datos de simulacións, xerados en contornas virtuais ou sistemas de proba.

Algún destes datos son accesibles directamente a partires dos sistemas de información propios (os datos que se rexistran nas bases de datos, o rexistro de actividade dos usuarios, datos emitidos por sensores e dispositivos IoT, ...), outros están dispoñibles de forma pública en forma de data sets (conxuntos de datos) ou accesibles a través de APIs de programación (por exemplo algunhas redes sociais permiten explotar a información que publican os usuarios empregando estas interfaces), pero hai outras fontes de información para as que é necesario realizar procesos específicos de procura de datos en Internet. O **web scrapping** é unha técnica automatizada para extraer datos de sitios web empregando programas ou scripts que navegan polas páxinas web, captan información específica e a estruturan nun formato útil para a análise, como CSV, Excel ou bases de datos.

4. Limpeza e preparación dos datos

Unha das principais fontes de información para procesar e analizar nunha organización son as bases de datos operacionais, nas que se gardan os datos xestionados polas propias aplicacións que dan servizo ao día a día da organización (o aplicativo de vendas, o software de xestión do almacén, os sistemas de xestión de clientes, etc.). Pero acceder directamente ás bases de datos destas aplicacións non adoita ser unha boa idea, xa que por unha banda se estaría a penalizar o rendemento das propias aplicacións (as consultas complexas acaparan moitos recursos e poderían deixar sen servizo ás aplicacións) e, tal como se indicou no paso anterior, estes datos xeralmente hai que procesalos previamente para poder explotalos. Para solucionar este problema existen unhas bases de datos especiais chamadas **datawarehouse** (almacéns de datos), que non son máis que bases de datos deseñadas especificamente para traballar con grandes cantidades de datos, nas que se carga regularmente a información procedente das bases de datos operacionais, aplicando no propio proceso de carga procesos **ETL** (Extract, Transform, Load) para limpar e homoxeneizar a información.

O feito de incorporar datos de moitas fontes diferentes implica dificultades á hora de poder analizalos, xa que para poder realizar comparacións temos que garantir que sempre esteamos a contar o mesmo e do mesmo xeito.

Supoñamos unha gran cadea comercial que conta con varios supermercados en distintas cidades do país. Os supermercados organízanse en diferentes seccións, cos seus responsables, as súas compras, os seus produtos, etc.

Para xestionar cada un dos supermercados, cada un deles conta cun sistema operacional (a súa aplicación de xestión do supermercado: o seu ERP) que almacenará nunha base de datos local toda a información necesaria para o seu funcionamento: seccións, produtos, provedores, vendas, etc. Cada supermercado accede e xestiona a súa propia información, e non todos os supermercados teñen que ter a mesma aplicación (os supermercados poden ser de distintas marcas e cada marca pode utilizar a súa propia aplicación, por exemplo).

Os usuarios de cada supermercado (os traballadores do supermercado) traballarán cada un coa súa aplicación para introducir e manter a información actualizada. Nestas bases de datos realízanse gran cantidade de operación cada día, xa que constantemente se están a rexistrar vendas, compras, novos produtos, cambios de prezos ou localizacións, etc.

Dende a xestión da organización precisan acceder a información de toda a organización, para o que precisarían acceder á información das bases de datos de todos os supermercados e comparar a información duns supermercados coa dos outros.


Os supermercados usan aplicacións diferentes, polo que as bases de datos utilizadas non teñen por que ser as mesmas. Ademais, cada supermercado terá o seu propio catálogo de produtos coas súas codificacións (os mesmos produtos poderían incluso ter nomes diferentes en cada supermercado).

Se dende a xerencia quixesen facer un estudo da evolución das vendas en todos os supermercados por sección e produto nos últimos 10 anos, se fose necesario consultar directamente as bases de datos de cada supermercado e integrar toda a información, probablemente sucederían dúas cousas:

- Que os supermercados estarían parados durante media hora (a consulta que se lanzaría en cada base de datos sería tan pesada que probablemente tardaría moito tempo e colapsaría as bases de datos, polo que as aplicacións non poderían traballar)
- Toda a información consultada sería necesario integrala posteriormente, polo que tardaríase moito tempo en dispor de toda a información

A solución para este problema pasa por crear un Data Warehouse (DW) no que periodicamente (pola noite, ou os domingos, cando o supermercado non funcione para non sobrecargar as bases de datos locais) se cargaría por medio dun proceso automático (o proceso ETL) a información das bases de datos de cada supermercado (na carga de cada domingo por exemplo se cargaría ao DW toda a información inserida ou actualizada nas bases de datos locais durante a última semana). O propio proceso ETL tamén se encargaría de integrar e homoxeneizar a información de todas as bases de datos locais: se temos un produto que nun supermercado ten o código 005 e noutro ten o código 134, cando se carga o a información dese produto no DW se asignaría sempre un código común, para que cando se consulten as vendas dese produto se conte sempre o mesmo en todos os supermercados.

Na base de datos do DW só se realizan insercións, modificacións e eliminacións durante estes procesos de carga, xa que unha vez finalizada a carga a información só se utilizará para consultas, polo que a súa prioridade será manter optimizadas as consultas para que os informes que se lancen obteñan resultados rapidamente.



5. O almacenamento de datos

Os datawarehouse son unha moi boa solución para almacenar datos estruturados, pero, tal como se indicou anteriormente, os datos que se xeran a partires dos sistemas de [big data](#) teñen dúas características:

- Son cantidades moi grandes de información: un servidor datawarehouse pode manexar ata petabytes de información, pero á medida que se incrementa a cantidade de información o rendemento vese moi penalizado, e os sistemas de [big data](#) poden superar sen problema esas cantidades de información.
- Teñen unha estrutura complexa, xa que poden ser tanto datos estruturados como non estruturados.

Para solventar estes problemas aparecen os data lakes. Un **data lake** é un repositorio centralizado que permite almacenar datos a calquera escala e de todo tipo, tanto estruturados como non estruturados (que se almacenan en plataformas específicas, como Hadoop, que facilitan a súa consulta e integración co resto de datos da organización).

Os datos almacenados nun data lake poden ser consultados de maneira tradicional (por medio de paneis de mando) pero tamén poden ser empregados para realizar análises en tempo real e operacións de aprendizaxe automática.



Modelo de capas dun data lake. Íñigo Sanz (dominio público)

Dar soporte a esta capacidade de almacenamento require moita capacidade de almacenamento para gardar toda a información necesaria, pero tamén moita capacidade de procesamento para poder realizar consultas nesa información de forma áxil (cousa complicada especialmente cando os datos non están estruturados).

Moitas pequenas organizacións probablemente non poidan permitirse dispor dos equipos necesarios para almacenar e procesar esa información, polo que a nube se presenta como unha solución idónea para esta problemática, e todos os grandes provedores de servizos na nube dispoñen da posibilidade de almacenar grandes cantidades de información (xeralmente por un prezo bastante razoable), e dispoñen de distintos formatos de almacenamento:

- **Almacenamento de ficheiros:** este tipo de almacenamento organiza os datos nunha xerarquía de cartafoles e ficheiros, de forma similar a un sistema de ficheiros tradicional, polo que se emprega xeralmente para almacenar documentos, imaxes e outros ficheiros non estruturados. Son de este tipo servizos como DropBox ou Google Drive.
- **Almacenamento de obxectos (object storage):** neste tipo de sistemas de almacenamento os ficheiros e os seus metadatos se almacenan como obxectos; cada un deles ten un número identificador único que permite ás aplicacións controlalos sen necesidade dun sistema de control de permisos adicional. Non é posible modificar os obxectos gardados, porque con cada cambio se crea un novo obxecto que contén a versión modificada do ficheiro orixinal, o que converte ao arquivamento de obxectos nun formato óptimo para solucións de backup e arquivado, e para almacenamento de ficheiros multimedia de só lectura (con poucos ou ningún cambio) como música, vídeos ou películas para servizos de visionado en liña, por exemplo. Son servizos de almacenamento de obxectos Amazon S3 ou Google [Cloud Storage](#).
- **Almacenamento en bloques (block storage):** o almacenamento en bloques divide os datos en bloques estruturados de tamaño homoxéneo cunha dirección propia, de forma que poden ser almacenados en distintos soportes de almacenamento e distintos servidores, e por medio de software acceder a eles rapidamente, independentemente da súa localización real. É ideal para aplicacións que requiren un acceso rápido e de baixa latencia aos datos, como bases de datos e sistemas de ficheiros virtuais. Son deste tipo sistemas como Amazon EBS ou Azure Managed Disks.

5.1. Vantaxes e desvantaxes do almacenamento na nube

O almacenamento na nube ofrece varias vantaxes con respecto a un sistema de almacenamento tradicional:

- Ubicuidade, xa que é posible acceder aos datos onde e cando se desexe, sempre e cando se dispoña de conexión a internet.
- Redución de custos de implantación, xa que non é necesario realizar un gran gasto, como o que implicaría comprar servidores con gran capacidade de memoria e almacenamento.
- Capacidade ilimitada: aspecto moi importante para empresas que precisan unha gran capacidade de almacenamento.
- Fiabilidade, xa que os servidores contan con numerosas copias dos datos subidos á nube.
- Seguridade: permite ter unha copia de seguridade automática dos datos a tempo real.
- Flexibilidade e personalización: o cliente decide canta capacidade de almacenamento contrata e con que condicións de servizo, e pode modificalo en calquera momento se o precisa.

A principal desvantaxe do almacenamento na nube é a dependencia de internet, e a necesidade de dispor dun ancho de banda elevado, xa que determinará a fluidez do envío de datos. Pero o almacenamento na nube tamén ten outras desvantaxes:

- **Dependencia do provedor:** o cliente está suxeito a posibles cambios na oferta ou incluso á cancelación do servizo.
- **Seguridade:** enviar datos a través da rede leva consigo certos riscos, porque non todos os provedores ofrecen cifraxa de datos. Así mesmo, a infraestrutura informática do provedor supón un branco potencial para ciberataques.
- **Protección de datos:** o almacenamento de información na nube pode ser problemático, *xa que* os servidores poden atoparse en calquera lugar do mundo, e os provedores localizados fóra da Unión Europea non sempre cumpren coa esixente normativa europea.

5.2. A seguridade dos datos

O **ADN dixital** fai referencia ao rastro único e persoal que deixamos no mundo dixital a través das nosas actividades en liña, dispositivos conectados e plataformas dixitais. Este rastrexo inclúe todos os datos que identifican ou describen as nosas accións e preferencias, os nosos hábitos e moito máis. Estes datos poden ser:

- **Datos activos:** información que proporcionamos directamente, como as publicacións en redes sociais, datos persoais en formularios en liña ou comentarios, likes e contido que compartimos.
- **Datos pasivos:** información que se recolle automaticamente sobre nós, como o historial de navegación, hábitos de compra e consumo de contidos ou información recollida por dispositivos IoT: teléfonos intelixentes, reloxs intelixentes, asistentes virtuais, etc.
- **Metadatos:** datos que describen outros datos, como a hora e lugar das fotos tomadas ou o tempo de actividade nas aplicacións.



O conxunto de datos que xeramos e que se rexistran en liña denomínase tamén **pegada dixital**. A pegada dixital é un compoñente do ADN dixital que fai referencia ás interaccións concretas e aos trazos específicos que deixamos en liña, mentres que o ADN dixital engloba unha visión máis ampla e detallada de todo o perfil de datos único que xera un individuo na contorna dixital.

Todos estes datos dos usuarios que se recollen e almacenan son moi valiosos para as compañías, e poden empregalos para ofrecer un mellor servizo (permite aos usuarios acceder de forma máis rápida e sinxela aos seus servizos), para analizar os gustos dos seus usuarios ou para analizar o funcionamento e rendemento das propias aplicacións.

Pero tamén implica unha perda importante de privacidade para os usuarios, un maior risco de ciberataques (é máis fácil caer se os atacantes coñecen datos persoais sobre nós) e sermos máis susceptibles a unha posible explotación comercial (as empresas poden personalizar os seus [anuncios](#), o que pode producir manipulación ou consumo non desexado), e tamén nos fai máis susceptibles á desinformación (a recollida e o mal uso de datos poden contribuír a campañas de desinformación).

Así e todo, non sempre está claro para os usuarios que información privada están a recoller as aplicacións que empregan e que uso se fai deles. É habitual, por exemplo, que grandes compañías do sector tecnolóxico (especialmente as vinculadas ás redes sociais) ofrezan servizos de maneira gratuíta para os usuarios: aínda que os usuarios non teñen que pagar por empregar os servizos, as compañías si que están a obter un réditto económico polo uso deses servizos, ben sexa directo a través dos ingresos publicitarios (cantos máis usuarios, maiores serán os ingresos que se obterán polos [anuncios](#)), ou ben indirecto, a través dos datos que recollen por medio deses servizos, xa que con eses datos poden alimentar as súas propias aplicacións de [big data](#) (coas que lograr, entre outras cousas, que os [anuncios](#) que amosan aos seus usuarios sexan máis efectivos), ou ben comerciar con eles (vendéndoos a terceiros aos que lles interese analízalos por medio das súas propias aplicacións de análise de datos e ciencia de datos).

O problema é que os usuarios non adoitan ser conscientes dos datos que están a ceder a estas aplicacións e do uso que as empresas están a facer deles, xa que xeralmente esta información está redactada en termos de uso que o usuario non le con atención e acepta sen máis cando se rexistra no servizo, para poder facer uso del.

É moi importante por tanto buscar un equilibrio para podermos obter a funcionalidade que nos ofrece a captación de datos por parte dos provedores e garantir ao tempo a seguridade dos nosos datos e a nosa privacidade. Para iso hai varias medidas que podemos levar a cabo:

- Configurar adecuadamente os nosos perfís, as nosas aplicacións e os nosos dispositivos:
 - Limitar quen pode ver a nosa información persoal.
 - Desactivar as opcións que permiten compartir datos con terceiros.
 - Limitar os permisos das aplicacións móbiles (autorizarlles o acceso só ao estritamente necesario: localización, cámara, micrófono, ...).
- Empregar unha boa política de contrasinais:
 - Usar contrasinais seguros
 - Utilizar contrasinais únicos para cada conta
 - Activar a autenticación de dous factores.
- Empregar ferramentas que garantan a nosa privacidade:
 - Navegadores enfocados na privacidade (DuckDuckGo, Brave ou Firefox con extensións de bloqueo de rastrexadores).



- VPNs (redes privadas virtuais), que enmascaran o enderezo IP dos nosos dispositivos e protexen a nosa actividade en redes públicas.
- Bloqueadores de rastreadores e [anuncios](#) (como uBlock Origin ou Privacy Badger).
- Ter coidado co que aceptamos e co que compartimos:
 - Evitar compartir datos persoais innecesarios en redes sociais ou plataformas.
 - Cando un servizo solicita información persoal para acceder a el, cuestionarnos se realmente é necesario proporcionar esa información.
 - Revisar as políticas de privacidade para entender como se manexan os nosos datos.
- Empregar un antivirus e manter actualizado o software e os dispositivos, xa que as actualizacións moitas veces inclúen parches de seguridade importantes.
- Monitorizar a nosa pegada dixital.
 - Buscar o noso nome ou alias regularmente para identificar información persoal pública.
 - Solicitar ás plataformas que eliminen información obsoleta ou irrelevante.

Os nosos provedores de servizos dixitais, pola súa parte, deben:

- Garantir a seguridade, a confidencialidade dos nosos datos e a privacidade, establecendo medidas de seguridade que restrinxan o acceso aos datos aos usuarios con permiso, tanto por medio de políticas de seguridade para evitar accesos indebidos como por medio da cifraxe.
- Garantir o cumprimento normativo: moitas das empresas que ofrecen servizos dixitais (redes sociais, compra en liña, etc.) son empresas chinesas ou americanas. Isto supón un problema á hora de garantir a nosa privacidade e a confidencialidade dos nosos datos porque estas empresas non sempre están suxeitas á normativa europea de protección de datos persoais e poden cambiar as condicións de uso e cesión dos datos sen notificalo correctamente aos usuarios.

En España é preciso cumprir as seguintes normativas cando se almacenan datos de carácter persoal:

- **Regulamento xeral de protección de datos (GDPR):** é unha normativa da Unión Europea que regula a protección dos datos persoais das persoas físicas.
- **Lei orgánica de protección de datos persoais e garantía dos dereitos dixitais (LOPDGDD):** a Lei orgánica 3/2018 complementa o GDPR en España e regula aspectos específicos adaptados ao contexto nacional (as cámaras de videovixilancia, a protección de menores, o envío de correos electrónicos e márketing ou a xestión de datos no ámbito laboral).
- **ISO 27001:** é unha norma internacional da organización internacional de estándares (ISO) que, aínda que non é obrigatoria, é unha referencia amplamente adoptada para a xestión da seguridade da información.
- **Esquema nacional de seguridade (ENS):** é obrigatorio para as administracións públicas e empresas que tratan datos no nome destas administración. Establece directrices de seguridade que deben levarse a cabo en todos os sistemas que xestionen datos persoais.

En determinados sectores (financeiro, sanitario, comercio electrónico, ...) existen normativas adicionais que regulan aspectos específicos relativos ao tratamento de datos no sector.

6. Análise de datos

A análise de datos examina datos históricos (xeralmente estruturados) para descubrir tendencias e padróns aplicando técnicas estatísticas e de visualización de datos para tomar decisións informadas. O seu principal obxectivo é comprender que sucedeu e por que.




Para analizar un conxunto de datos, temos dúas alternativas:


- Podemos partir do coñecemento de analistas expertos no negocio, que identifiquen os principais indicadores de seguimento da actividade da organización (os indicadores clave de desempeño, **KPI**, como poden ser a evolución dos prezos dos produtos, o equilibrio entre gastos e ingresos, etc.). A partir destes indicadores, os analistas de datos definen informes e paneis detallados (chamados **paneis de mando**) que permiten monitorizar estes KPIs das organizacións para tomar decisións baseadas en datos.



- Por medio de técnicas estatísticas podemos levar a cabo analíticas avanzadas, coas que poderemos crear modelos predictivos ou clasificadores que nos permitirán predicir resultados futuros baseándose en datos históricos. Estes modelos se utilizan en diversas áreas, como finanzas, marketing, saúde ou educación, para tomar decisións informadas. Dúas das técnicas máis comúns de modelado predictivo son a regresión lineal e o análise de clústeres.
 - Regresión lineal: é unha técnica estatística supervisada que se emprega para predicir unha variable continua en base á súa relación con outras variables. Pódese empregar por exemplo para calcular o prezo dunha casa en base a características como o seu tamaño, localización ou número de habitacións, ou estimar as vendas dun produto en función do gasto en publicidade, o prezo ou a tempada.



- Análise de clústeres: é unha técnica de aprendizaxe non supervisada que se emprega para descubrir estruturas ou agrupacións dentro dos datos. É útil cando non se coñece de antemán a estrutura dos datos e se desexa explorar patróns ocultos.



6.1. Análise de clústeres

A análise de clústeres é unha técnica de aprendizaxe non supervisada que consiste en agrupar elementos en grupos ou clústeres, de xeito que os elementos do mesmo grupo serán máis parecidos entre si do que se parecen que aos elementos dos outros grupos.


Por medio deste tipo de técnicas podemos analizar novos elementos e predicir a cal dos grupos definidos anteriormente pertencería, e poderemos dese modo aventurar características que terá en común co resto de elementos do seu grupo, polo que son moi empregadas en aplicacións como a segmentación de clientes, a clasificación de imaxes, ou en bioinformática para agrupar xenes con patróns de expresión similares, por exemplo.

Un dos algoritmos de análise de clústeres máis empregado é o **k-means**, que funciona do seguinte xeito:


1. O primeiro que haberá que indicar será o número k de grupos (clústers) que se van crear.
2. Se escollen aleatoriamente k puntos como centroides dos grupos (se representamos gráficamente o clúster, o centroide será o centro xeométrico do clúster).




3. Analízase cada un dos elementos do dataset e se asigna ao clúster que teña o seu centroide máis cerca dese elemento.



4. Unha vez asignados todos os elementos do dataset, se recalculan os centroides collendo o promedio dos puntos correspondentes aos elementos de cada clúster.



5. Repítense os pasos 3 e 4 ata que os centroides non cambien significativamente, momento no que se considerará que os grupos están ben definidos e cada elemento forma parte do grupo que lle corresponde.



7. Ciencia de datos

A **ciencia de datos** é un campo interdisciplinario que busca extraer coñecemento a partir de grandes volumes de datos, tanto estruturados como non estruturados, combinando métodos e tecnoloxías procedentes das matemáticas, a estatística e a informática, para proporcionar información non só de natureza descritiva (que explique o sucedido) senón tamén predictiva (que prognostique o que podería suceder) e prescritiva (que recomende accións para levar a cabo).



A ciencia de datos consiste, por tanto, en aplicar técnicas de intelixencia artificial ao [big data](#) para construír modelos que permitan obter información, predicir resultados e resolver problemas sen a intervención humana.

Estas técnicas de intelixencia artificial son basicamente algoritmos de aprendizaxe que a partires duns datos de adestramento permiten definir un modelo que predí uns resultados.

As técnicas de intelixencia artificial máis empregadas no modelado de análises predictivas son a aprendizaxe automática (**machine learning**) e a aprendizaxe profunda (**deep learning**).

En ambos os casos os sistemas aprenden a resolver os problemas a partires dos conxuntos de datos cos que os adestramos, ben de forma **supervisada** (cando os conxuntos de datos de adestramento están previamente etiquetados por humanos) ou ben de forma **non supervisada** (cando os conxuntos de datos non están etiquetados). A diferenza entre ambos conceptos radica na forma en que aprenden os seus algoritmos: a aprendizaxe automática está baseada en algoritmos que son capaces de descubrir padróns nun conxunto de datos (redes bayesianas, máquinas de vectores de soporte, análise de clústers, etc.), mentres que a aprendizaxe profunda trata de simular o comportamento das conexións das neuronas do cerebro humano para analizar os datos (empregando tecnoloxías como as redes neuronais convolucionais para recoñecemento de imaxes ou as redes neuronais recorrentes para o procesamento da linguaxe natural).

Podemos considerar ao deep learning como un subconxunto do machine learning no que a extracción de características do proceso para a aprendizaxe está practicamente automatizada, polo que require un grao de intervención humana moito menor.

A cantidade de datos dos que dispoñamos para adestrar o modelo determinará cal deles será máis axeitado: se temos un conxunto de datos de adestramento pequeno os resultados serán similares empregando calquera dos dous modelos, pero a partires dun certo volume de datos os resultados obtidos polos sistemas de deep learning son moito máis precisos, xa que son capaces de aprender por si mesmos.

7.1. Machine learning

O sistemas de machine learning precisan de asistencia humana para indicar aos algoritmos como aprender a determinar que características de entrada teñen que darse para obter un resultado concreto, e este proceso de aprendizaxe precisa de **datos etiquetados** (que fan referencia a resultados xa coñecidos dos que coñecemos o resultado).



Empréganse polo xeral para realizar análises predictivas (para predicir o comportamento dos seus clientes, reaccións ante cambios de prezos, optimizar a produción ou prever a fraude). Este tipo de análises empregan modelos matemáticos, que poden ser de dous tipos:

- Os modelos de **clasificación** permiten, tal como indica o seu nome, facer clasificacións: clasificar os pacientes por nivel de uso de sistema sanitario, clasificar os clientes por fidelidade ou por reacción ante as ofertas, etc.
- Os modelos de **regresión** empréganse para predicir valores: estimar a predición de vendas, a incidencia da gripe, o beneficio estimado que obteremos dun determinado tipo de cliente, etc.


Estes modelos empregan métodos matemáticos para prever eventos ou resultados futuros a partires de datos do pasado. O modelo se adestra por medio dunha **aprendizaxe supervisada** que parte dun conxunto de datos de adestramento que emprega para axustar as variables do modelo matemático para facer as súas predicións.

Un dos modelos predictivos máis sinxelos é o das árbores de decisión. O seu funcionamento é o seguinte:

- Partimos dun conxunto de datos “históricos” composto de variables e resultados medidos no pasado: as variables son todas aquelas características que poden influír no resultado, e o resultado é o que queremos predicir. Dicimos que estes datos están etiquetados, xa que para cada combinación das variables de entrada coñecemos o resultado (a etiqueta) ao que dan lugar. Un exemplo podería ser os resultados das carreiras de cabalos: o noso conxunto de datos podería conter os datos das carreiras dos últimos 10 anos, por exemplo, de maneira que para cada cabalo participante se incluírían todas as variables que poderían afectar ao resultado da carreira (a súa raza, a súa idade, o peso, a altura do jockey, etc.), e o seu resultado na carreira.
- O primeiro paso será dividir este conxunto de datos en dúas (ou tres) partes:
 - O conxunto de datos de **adestramento** (training data), que será do que inicialmente aprenda o modelo. En ocasións este conxunto de datos pode estar á súa vez dividido en dúas partes: os datos de adestramento e os datos de validación (validation data), que tamén forman parte do proceso de adestramento pero se manteñen por separado para axustar os parámetros do modelo. Este conxunto de datos debería ter aproximadamente o 90 % dos datos de partida (un 10 % para os datos de validación e o 80 % restante para os datos de adestramento).
 - O conxunto de datos de **comprobación** (test data) será o que empregue, unha vez finalizado o adestramento do modelo, para validar a súa eficacia. O conxunto de datos de comprobación debería ter máis ou menos 10 % do total dos datos.

No noso conxunto de datos poderíamos destinar os datos dos anos anteriores ao conxunto de adestramento, e reservar os datos deste ano para facer a comprobación.

- A partir dos datos de adestramento constrúese un modelo de aprendizaxe para predicir os resultados. Neste caso o modelo será a árbore de decisión, que clasifica as variables do conxunto de datos de adestramento e lles asigna distintos pesos para poder predicir o resultado con base nesas variables. No exemplo anterior, poderíase crear unha árbore de decisión da seguinte maneira:



- Unha vez construído o modelo, aplícase sobre os datos do conxunto de comprobación para verificar se o resultado estimado coincide co resultado real, e así validar o modelo. Para iso se define a “media de error absoluto” (**MAE** - mean absolute error), que nos dá unha medida da bondade do noso modelo. No exemplo anterior, poderíamos calcular o erro como o resultado previsto menos o resultado real do cabalo na carreira. A media dos erros obtidos en cada un dos rexistros de comprobación nos daría a MAE do noso modelo.

Hai que ter en conta, non obstante, que non todos o erros son iguais. Cando o modelo falla, podemos estar ante un falso positivo (o modelo clasificouno como positivo cando non o era) ou un falso negativo (o modelo clasificouno como negativo cando era positivo).

Valor estimado	Valor real	
	Verdadeiro	Falso
Verdadeiro	Acerto	Falso positivo
Falso	Falso negativo	Acerto

Non sempre estes erros teñen a mesma importancia, polo que o MAE non sempre é a mellor medida para avaliar un modelo, e ás veces cómpre ter en conta unicamente un destes tipos de erro: se pensamos por exemplo nun sistema de detección precoz de cancro a partir de imaxes, por exemplo, un falso positivo non terá moita incidencia (análises posteriores poderían confirmar que está todo ben e listo), pero un falso negativo podería ter consecuencias fatais.

Cantas máis variables teñamos no noso conxunto de datos e cantos máis datos teñamos, maior poderá ser a profundidade da nosa árbore e mellor será a súa precisión, pero hai que ter en conta que cada nivel de decisión implica dividir o noso conxunto de datos, polo que á medida que baixamos nas ramas da nosa árbore menos datos ten o modelo para facer unha estimación, e daquela deberemos buscar un equilibrio entre a cantidade de datos que teñamos e a profundidade das árbores que creemos:

- Se temos un só cabalo de menos de cinco anos de idade de raza árabe que coincidiu que gañou a súa carreira, o modelo entenderá que os cabalos árabes de máis de cinco anos sempre gañan. Isto é o que se denomina **sobreadestramento** (overfitting), e se produce cando as árbores de decisión teñen tantos niveis que quedan sen datos e, por tanto, reflicten a realidade do conxunto de datos de adestramento.
- Se pola contra temos moi poucas variables relevantes e poucos niveis de decisión na nosa árbore, as estimacións se farán con base nunha cantidade de datos moi grande, que englobará situacións moi heteroxéneas, polo que tampouco será moi fiable. Isto é o que se denomina **infraadestramento** (underfitting): no exemplo exposto anteriormente, se temos datos de carreiras de dez anos e unicamente temos os niveis de decisión definidos na árbore do exemplo, atoparemos que nos últimos dez anos houbo miles de cabalos de máis de cinco anos cun xinete con peso maior de 60 kg, que ocuparon todas as posicións posibles na chegada. A estimación do resultado non pode ser moi fiable, xa que os datos non se segmentaron suficientemente.

Para tratar de evitar o overfitting e o underfitting, as técnicas actuais permiten definir modelos máis sofisticados, compostos por múltiples árbores de decisión, con distintos niveis. Isto é o que se denomina o **random forrest** (que poderíamos traducir como un “bosque aleatorio”). Estes modelos crean diversas árbores e estiman o resultado final facendo a media dos resultados obtidos por cada unha das árbores do bosque.



7.2. Deep learning


Os sistemas de deep learning simulan redes neuronais artificiais que tratan de imitar as neuronas do cerebro humano e a súa forma de aprender, e permiten resolver problemas de recoñecemento de padróns sen intervención humana, como a clasificación de imaxes, a tradución de idiomas, os xogos ou o recoñecemento de voz.



As redes neuronais profundas (DNN) están compostas de varias capas que procesan a información en múltiples etapas sucesivas para analizar as interaccións que se establecen entre os datos observados. Cada capa está formada por varios nodos ou neuronas, e cada un deles estará conectado co resto de nodos da súa capa e cos nodos das capas adxacentes: os nodos intercambian mensaxes entre eles e interpretan a información que reciben.



Canta maior sexa a profundidade do sistema (o número de capas), maior será o nivel de abstracción do sistema, maior será o número de datos dos que permitirá aprender e menor será a marxe de erro: ata hai ben pouco tempo estas redes estaban limitadas pola potencia de cómputo dos sistemas informáticos, polo que tiñan unha complexidade limitada, pero os avances en [big data](#) e IA permitiron desenvolver redes neuronais moito máis complexas e precisas (cantos máis datos e maior tempo pase aprendendo o sistema, mellores resultados obterá).



Un exemplo de sistema de deep learning son os sistemas de recoñecemento facial. Estes sistemas parten dun conxunto de imaxes etiquetadas previamente por humanos. O algoritmo clasifica estas imaxes de forma autónoma: comezan aprendendo a detectar bordos e liñas de caras, nas capas sucesivas pasa a recoñecer partes máis significativas das caras, e finalmente aprende a detectar representacións xerais de caras (é dicir: vai incrementando paulatinamente o nivel de abstracción que é capaz de detectar).

Unha vez obtidos os resultados os compara co etiquetado polos humanos para comprobar se obtivo o resultado esperado ou o debe procesar de novo para mellorar a súa capacidade de detección.

Co tempo, o programa se adestra a si mesmo, incrementando a súa precisión.

8. Usos do big data

A análise dos datos do [big data](#) permite detectar padróns de comportamento ou tendencias ocultas a simple vista nos datos, e así prever situacións futuras e facilitar a toma de decisións que permitan aproveitar oportunidades e tendencias do mercado, facendo que as organizacións sexan máis eficientes, eficaces e competitivas.

Existen múltiples campos nos que se están a empregar a día de hoxe tanto a análise de datos como a ciencia de datos.

Análise de datos

- Toma de decisións baseada en datos: dispor de información precisa e relevante facilita a toma de decisións informadas. A análise de datos históricos e en tempo real permite predicir tendencias (de vendas, de necesidades de recursos, de requisitos de inventario, ...), avaliar riscos e oportunidades, e tomar decisións estratéxicas que estean apoiadas por datos sólidos. Empresas como Amazon, por exemplo, empregan o [big data](#) para prever a demanda durante o Nadal para axustar os seus inventarios e o seu persoal para esas datas.
- Segmentación de clientes: a análise dos datos dos clientes permite clasificalos en "tipos" e identificar características compartidas (como os comportamentos de compra, os produtos máis adecuados para cada tipo de cliente ou incluso suxerir que persoas serán máis compatibles nunha aplicación de citas), o que axuda a crear campañas de márketing personalizadas, mellorar a retención de clientes e aumentar as vendas.
- Optimización de procesos: a análise de grandes volumes de datos permite ás empresas identificar ineficiencias e áreas de mellora nos seus procesos operativos para optimizar a produción, a cadea de subministración, o rendemento dos provedores, os prazos de entrega, a xestión de inventarios e outros procesos clave, para mellorar a eficiencia operativa, reducir custos e aumentar a produtividade.
- Xestión de riscos: analizar datos históricos de incidentes pasados e padróns de comportamento, pode facilitar a detección destas situación para predicir e mitigar riscos financeiros, operativos ou de seguridade. As entidades financeiras empregan modelos de riscos baseados en datos para avaliar a probabilidade de incumprimento dos préstamos e axustar as súas políticas de crédito para minimizar o risco.
- Asistencia sanitaria: a análise de datos rastrea os resultados dos pacientes e permite identificar factores de risco, identificar os tratamentos máis axeitados ou prever a posibilidade de reingreso dun paciente.
- Análise de sitios web: a análise das páxinas vistas, as taxas de rebote ou as taxas de compromiso permite comprender as interaccións dos usuarios cos sitios web, e facilita que o deseño dos sitios web sexa máis eficaz e que os usuarios poidan ter unha mellor experiencia de usuario.

Ciencia de datos

- Mantemento predictivo: os fallos das máquinas poden causar importantes tempos de inactividade e perdas económicas. Para reducir estes fallos é posible situar sensores ao longo de toda a liña de produción e analizar os datos que xeran por medio da ciencia de datos para prever cando unha máquina pode fallar. Este proceso implica analizar fallos pasados e predicir os futuros baseándose en padróns complexos de datos de sensores en tempo real.
- Detección de fraude: a fraude financeira adoita ser complexa e responde a unha casuística moi diversa, o que dificulta a súa detección por medio de sistemas baseados en regras. Os casos de fraude ou mesmo os casos de branqueo de capitais, con todo, son casos de uso moi axeitados para a utilización de técnicas de deep learning, xa que precisamente son casos diferentes ao comportamento habitual das transaccións comerciais, e por tanto teñen padróns de comportamento distinto, que poden ser detectados por medio deste tipo de técnicas. Un exemplo de empresa que emprega estas tecnoloxías é PayPal, que emprega deep learning para detectar pagamentos fraudulentos.
- Sistemas de recomendación: a análise de datos só pode segmentar os usuarios en función do seu comportamento pasado, mentres que hai empresas, como Netflix ou Amazon, que por medio do deep learning predín as preferencias en función dos padróns dos datos e recomentan produtos ou películas aínda que os usuarios non comprasen nin viran nunca produtos similares.
- Procesamento da linguaxe natural (PNL): os asistentes de voz ou a atención ao cliente a través de chatbots son aplicacións directas das técnicas de procesamento da linguaxe natural. O machine learning e o deep learning permiten comprender a semántica e o contexto da linguaxe, algo que a análise de datos tradicional non pode conseguir.
- Recoñecemento de imaxes: o recoñecemento de imaxes é probablemente unha das utilizacións máis habituais a día de hoxe destas tecnoloxías. Os teléfonos móbiles teñen sistemas de recoñecemento facial para o propietario do teléfono para que só esa persoa poida desbloquealo; no sector sanitario cada vez é posible detectar máis enfermidades (como certos tipos de cancro) de maneira precoz; os vehículos autónomos empregan esta tecnoloxía para recoñecer os obxectos na estrada; as redes sociais permiten identificar aos contactos e etiquetalos automaticamente cando se cargan fotos novas; os sistemas de videovixilancia permiten identificar a persoas a través dos seus trazos faciais ...

- Recoñecemento de voz: esta é outra das áreas nas que a IA está máis directamente á disposición dos usuarios. Hai aplicación que permiten “escoitar” a fala e que a traducen a texto; os asistentes dixitais (como Siri, Cortana, Alexa ou Google Now) empregan deep learning para o recoñecemento de voz e para procesar a linguaxe natural; algunhas aplicacións de videoconferencia (como Skype) permiten traducir conversacións faladas en tempo real, ...
- Análise de sentimentos: a análise de sentimentos consiste en analizar datos non estruturados procedentes das valoracións e dos comentarios dos clientes para coñecer o acollemento por parte dos clientes a novos produtos ou decisións (cambios de prezo, por exemplo), para poder medir e controlar o impacto destas medidas. Os científicos de datos usan o procesamento da linguaxe natural e a aprendizaxe automática para discernir os sentimentos detrás dos datos de texto.
- Cálculo de rutas: o cálculo de rutas óptimas foi desde hai ben tempo unha problemática coa que pelexaron matemáticos, físicos e xa máis recentemente informáticos. O big data permite non só predicir que rutas son máis rápidas, senón tamén identificar posibles atascos ou detectar que traxecto minimiza o consumo de combustible para obter a alternativa máis eficiente.

Smart cities e smart buildings

O concepto de **smart city** ou cidade intelixente describe unha cidade que utiliza tecnoloxías dixitais e de comunicación avanzadas para mellorar a calidade de vida dos seus cidadáns, optimizar a xestión dos recursos e servizos urbanos e promover o desenvolvemento sostible. Estas cidades integran datos, infraestruturas e tecnoloxía nun sistema interconectado para abordar os desafíos urbanos, como o tráfico, a contaminación e a seguridade.



Pero a “intelixencia” destas cidades non se restrinxe ás tarefas e operacións públicas e da Administración, senón que nelas cobran gran importancia os **smart buildings** ou edificios intelixentes: construcións que empregan tecnoloxías avanzadas, como o internet das cousas (IoT), sistemas automatizados e análise de datos, para xestionar e optimizar as súas operacións, mellorar a comodidade dos ocupantes, reducir o consumo enerxético e minimizar o impacto ambiental.

As cidades intelixentes presentan as seguintes características:

- Uso de tecnoloxías IoT (internet das cousas): os sensores e os dispositivos conectados recollen datos en tempo real sobre diversos aspectos da cidade, como o tráfico, a calidade do aire ou o consumo de enerxía.
- Xestión de datos e intelixencia artificial: os datos recollidos son procesados e analizados mediante ferramentas de [big data](#) e IA para tomar decisións fundamentadas e automatizar procesos.
- Conectividade avanzada: usando redes de comunicación rápidas e fiables, como 5G, para garantir unha transmisión eficiente de datos.
- Eficiencia enerxética: sistemas que optimizan o uso enerxético, fomentan as fontes renovables e reducen o consumo en infraestruturas públicas e privadas.
- Mobilidade intelixente: solucións de transporte que inclúen sistemas de transporte público conectados e eficientes, o uso de vehículos eléctricos e compartidos ou a xestión do tráfico en tempo real.
- Sostibilidade: implantación de tecnoloxías para reducir as emisións, optimizar o uso da auga e promover unha xestión adecuada dos residuos.
- Participación cidadá: plataformas que permiten aos cidadáns interactuar coa Administración pública, denunciar problemas urbanísticos e participar nas decisións comunitarias.
- Seguridade e vixilancia intelixentes: sistemas de cámaras, dróns e ferramentas de recoñecemento facial para mellorar a seguridade e a resposta ás emerxencias.

9. Recursos

Datasets

- [Catálogo de datos do Goberno de España](#)
- [Portal de goberno aberto da Xunta de Galicia](#)
- [Instituto Galego de Estatística](#)
- [Portal de estatísticas da Consellería de Emprego](#)
- [Portal de datos abertos do SERGAS](#)
- [Data commons](#)
- [Datos públicos de Google](#)
- [Kaggle](#)
- [Portal europeo de datos abertos](#)
- [UC Irvine](#)

Ferramentas para o análise de datos

- [Microsoft PowerBI](#): software de Microsoft que dispón dunha versión gratuita que permite realizar tarefas de adquisición, transformación e análise de datos.
- [Looker Studio de Google](#): Permite crear visualizacións de datos online a partir de diferentes fontes, como arquivos locais, follas de cálculo de Goggle, bases de datos, gran variedade de APIs, etc. Ten certas funcionalidades para transformación de datos, pero moi limitadas. Os datos se suben á conta de drive ou ao Google [Cloud](#) Storage, polo que ten un límite de espazo gratuito.
- [Tableau Public](#): ferramenta online para a visualización de datos, cunha interfaz moi intuitiva e gran variedade de gráficos e mapas. Permite a transformación e análise de datos con Tableau Prep, pero esta ferramenta non está incluída na versión gratuita.
- [Klimate](#): ferramenta gráfica orientada á ciencia de datos. Permite combinar nun proceso distintos compoñentes que realizar tarefas de transformación de datos (ETL), e ferramentas de análise de datos (visualización de datos) e ciencia de datos (minería de datos, creación de modelos estatísticos, etc). Ten unha licenza open source, polo que pode empregarse de maneira gratuita.
- [Metabase](#): Ferramenta open source para o análise de datos. Permite realizar certas transformacións de datos pero moi básicas. Dispón tamén dunha versión na nube, pero esa xa non é gratuita.
- [Infogram](#): ferramenta online para análise de datos.
- [Datawrapper](#): outra ferramenta online para análise de datos.
- [Qlik Sense](#): enfocado na análise de datos interactiva. Permite realizar transformacións de datos por medio de scripts. Dispón dunha versión de proba de 30 días.
- [Domo](#): plataforma na nube con ferramentas de transformación de datos e análise en tempo real. Dispón tamén dunha versión de proba de 30 días.

Ferramentas para ciencia de datos

- [Orange Data Mining](#): ferramenta de escritorio (con versión gratuita e portable, que se pode executar en calquera sistema operativo), moi potente e cun interfaz gráfico que permite realizar analíticas moi complexas de forma doada.
- [LearningML](#): ferramenta online e gratuita para crear clasificadores de texto, imaxes ou número con algoritmos de Machine Learning supervisados.
- [Teachable Machine](#): ferramenta web de Google para crear modelos de aprendizaxe automática de maneira sinxela.
- [Lobe](#): aplicación gratuita de Microsoft para entrenar modelos de clasificación de imaxes sen código.
- [Create ML](#): plataforma de Apple (só para MAC) para entrenar modelos ML sen código a través da aplicación Xcode. Soporta imaxes, texto e series temporais.
- [Google AutoML Vision](#): tamén de Google, ten unha versión gratuita con funcionalidade limitada que permite crear modelos personalizados de visión por computadora sen código.

Repositorios de imaxes creative commons

- [Listado do intef](#) de repositorios de imaxes abertos.

Para saber máis

- [Introdución ao Machine Learning](#)
- [Caso práctico de Machine Learning](#)
- [Introdución ao Deep Learning](#)

- [Documentación oficial PowerBI](#)